다중 홉 질의응답을 위한 답변 이득 예측 기반 단계별 검색 제어

Stepwise Retrieval Control Based on Predicted Answer Gain for Multi-Hop Question Answering

이정호*, 심춘보, 정세훈*****

(Jeong Ho Lee, Chun Bo Sim, Se Hoon Jung)

요 약

본 연구는 다중 홉 질의응답에서 현재 근거와 답변 상태에 따라 추가 검색 여부를 결정하여, 고정 검색보다 검색 횟수를 줄이면서 답변 성능을 유지하거나 높이는 단계별 검색 제어 정책을 제안한다. 제안 정책은 질문 특성, 검색 점수, 근거 변화 및 현재 답변 특징을 이용하여 후속 검색의 최대 F1 이득을 그래디언트 부스팅 회귀 모델로 예측하고, 단계별 임곗값에 따라 STOP 또는 SEARCH를 선택한다. 질의 갱신과 답변 생성에 사용하는 Qwen3-8B는 고정하고 검색 정책만 학습하였다. HotpotQA, MuSiQue 및 2WikiMultiHopQA의 학습 분할에서 시드별로 각각 2,000문항을 추출하여 5개 정책을 학습하고, 전체 검증 분할에서 오프라인 궤적 재생 평가를 수행하였다. 5개 시드 평균에서 제안 정책은 고정 4회 검색보다 F1이 각각 0.27점, 0.49점, 0.79점 높았으며, 검색 횟수는 27.40%, 20.79%, 28.99% 감소하였다. 동일한 검색 깊이 분포의 무작위 종료 기준선보다도 F1이 각각 0.55점, 1.36점, 1.63점 높았다. 다만 단계별 중간 답변 생성으로 출력 토큰과 추정 지연시간은 증가하였다. 이러한 결과는 학습된 정책의 질문별 검색 배분 효과와 상태 관측에 따른 생성 비용의 트레이드오프를 보여준다.

■ 중심어 : 다중 홉 질의응답 ; 검색 증강 생성 ; 적응형 검색 ; 검색 깊이 제어 ; 답변 이득 예측

Abstract

This study proposes a stepwise retrieval control policy for multi-hop question answering that reduces retrieval rounds while maintaining or improving answer quality compared with fixed-depth retrieval. The policy uses question characteristics, retrieval scores, changes in evidence, and current answer features to predict the maximum F1 gain attainable through subsequent retrieval using a gradient-boosting regressor. It then selects STOP or SEARCH by comparing the predicted gain with a stage-specific threshold. Qwen3-8B remains frozen for query reformulation and answer generation, and only the retrieval policy is trained. For each of five training-sample seeds, 2,000 questions were sampled from the training split of each of HotpotQA, MuSiQue, and 2WikiMultiHopQA. The five resulting policies were evaluated through offline trajectory replay on the full validation splits. Averaged across the five seeds, the proposed policy achieved F1 scores 0.27, 0.49, and 0.79 points higher than fixed four-round retrieval while reducing retrieval rounds by 27.40%, 20.79%, and 28.99%, respectively. It also achieved F1 scores 0.55, 1.36, and 1.63 points higher than a random-stopping baseline with the same retrieval-depth distribution. However, intermediate answer generation increased output tokens and estimated latency. These results demonstrate the benefits of the learned policy for allocating retrieval rounds according to question state, together with the trade-off in generation cost required to observe intermediate answer states.

■ keywords : Multi-hop Question Answering ; Retrieval-Augmented Generation ; Adaptive Retrieval ; Retrieval Depth Control ; Answer-Gain Prediction

Ⅰ. 서 론

다중 홉 질의응답에서는 여러 문서에 분산된 정보를 검색하고 연결하여 답을 도출해야 한다. 최초 질문만으로 검색하면 후속 추론에 필요한 근거를 충분히 확보하지 못할 수 있으므로, 검색 결과를 바탕으로 질의를 갱신하고 추가 근거를 확보하는 반복 검색이 필요하다. 그러나 검색을 반복한다고 해서 답변 성능이 항상 높아지는 것은 아니다. 이미 충분한 근거를 확보한 질문에서는 추가 검색의 이득이 작을 수 있으며, 다른

* 정회원, 국립순천대학교 스마트융합전공 멀티미디어공학과
** 정회원, 국립순천대학교 인공지능공학부
*** 정회원, 국립순천대학교 컴퓨터공학과

본 연구는 2026년 과학기술정보통신부 및 정보통신기획평가원의 SW중심대학사업 지원을 받아 수행되었음"(2026-0-00311)
이 성과는 정부(과학기술정보통신부)의 재원으로 한국연구재단의 지원을 받아 수행된 연구임(No. RS-2024-00407739)
This research was supported by Basic Science Research Program through the National Research Foundation of Korea (NRF) funded by the Ministry of Education (RS-2025-25434896)
접수일자 : 2020년 03월 23일 (학회측 사용란)
수정일자 : 1차 2020년 03월 23일, 2차 2020년 04월 23일(학회측 사용란)
게재확정일 : 2020년 03월 28일 (학회측 사용란)
교신저자 : 심춘보 e-mail : cbosim@scnu.ac.kr

질문에서는 여러 단계의 검색을 거쳐야 필요한 정보가 확보될 수 있다.

따라서 반복 검색에서는 다음 근거를 찾는 것뿐 아니라, 현재 상태에서 검색을 계속할 필요가 있는지를 판단해야 한다. 검색 깊이를 미리 고정하면 검색 과정에서 변화하는 근거와 답변 상태를 종료 결정에 반영하기 어렵다. 이를 개선하려면 현재까지 확보한 정보와 생성 답변을 관찰하고, 후속 검색으로 얻을 수 있는 답변 이득에 따라 추가 검색 여부를 결정할 필요가 있다.

본 연구는 현재 검색 및 답변 상태로부터 후속 검색의 답변 이득을 예측하는 경량 그래디언트 부스팅 기반 검색 제어 정책을 제안한다. 정책은 최초 검색과 답변 생성이 완료된 이후 각 단계에서 질문 특성, 검색 점수, 근거 변화 및 현재 답변의 특징을 입력받아 STOP 또는 SEARCH를 선택한다. 학습에는 저장된 검색 궤적과 정답을 이용해 구성한 미래 답변 이득을 사용하며, 실제 의사결정에는 정답을 사용하지 않는다. 질의 갱신과 답변 생성 모델은 고정하고 검색 제어 정책만 학습하며, 최대 4회의 검색 상한 안에서 질문별 검색 횟수를 조절한다.

본 연구의 목적은 학습된 정책을 이용하여 고정 검색보다 검색 횟수를 줄이면서 답변 성능을 유지하거나 높이는 것이다. 이를 검증하기 위해 3개의 다중 홉 질의응답 데이터셋에서 고정 검색 방식과 비교하고, 동일한 검색 깊이 분포의 무작위 종료 기준선을 통해 질문 상태에 따른 검색 배분 효과를 분석한다. 또한 학습 표본을 달리한 5개 시드로 결과의 변동을 확인하고, 중간 답변 생성에 따른 출력 토큰과 추정 지연시간을 함께 평가하여 검색 횟수와 생성 비용 사이의 트레이드오프를 분석한다.

Ⅱ. 관련 연구

1. 다중 홉 질의응답과 반복 검색

검색 증강 생성(RAG)[1]은 외부 문서에서 검색한 정보를 언어모델의 답변 생성에 결합한다. 그러나 여러 문서의 사실을 연결해야 하는 다중 홉 질의응답에서는 최초 질문만으로 수행한 검색이 후속 추론에 필요한 근거를 모두 찾지 못할 수 있다. IRCoT[2]는 중간 추론과 검색을 번갈아 수행해, 앞서 얻은 정보가 다음 검색을 안내하도록 하였다. 최근 ChainRAG[9] 역시 누락된 핵심 개체를 보완하며 검색 질의를 단계적으로 갱신한다. 이러한 연구가 다음 근거를 어떻게 찾을 것인가에 기여했다면, 본 연구는 검색으로 얻은 근거와 현재 답변을 바탕으로 다음 검색이 필요한가를 판단하는 문제에 초점을 둔다.

2. 적응형 검색과 검색 시점 제어

질문의 특성에 따라 검색 전략을 달리하는 연구도 진행되었다. Adaptive-RAG[3]는 입력 질문의 복잡도를 예측해 검색 없음, 단일 검색, 반복 검색 가운데 전략을 선택한다. MBA-RAG[10]는 질문 복잡도에 따른 전략 선택에 밴딧 기법을 적용하고, 정확도와 검색 비용을 함께 고려한다. 두 방법은 질문에 맞는 검색 전략을 선택한다는 점에서 고정 검색 방식과 구별되지만, 본 연구처럼 각 검색 후 생성된 답변을 관찰해 계속 여부를 결정하는 설정과는 의사결정 시점이 다르다.

생성 과정의 신호를 이용해 검색을 촉발하는 접근도 있다. FLARE[11]는 앞으로 생성할 문장의 저신뢰 토큰을 단서로 추가 검색을 수행하며, DRAGIN[12]은 생성 중 언어모델의 정보 요구를 고려해 검색 시점과 질의를 결정한다. 본 연구는 토큰 단위의 검색 촉발보다 다중 홉 질의응답의 완료된 검색 단계를 의사결정 단위로 삼는다. 이때 검색 점수뿐 아니라 새 근거의 변화와 현재 답변·근거 연결 상태를 함께 사용하고, 후속 검색이 답변 F1을 얼마나 개선할지를 학습 목표로 둔다.

3. 학습 기반 순차 검색 정책

검색 단계마다 행동을 학습해 결정한다는 발상 자체는 새로운 것이 아니다. AISO[4]는 수집한 근거를 상태로 사용하고, 모방학습을 통해 여러 검색 행동 또는 답변 행동을 순차적으로 선택한다. Self-RAG[13]는 언어모델에 자기성찰 토큰을 학습시켜 검색 필요성과 생성 결과를 판단한다. 다중 홉 질의응답을 대상으로 한 SiGIR[14]는 중간 추론에 대한 자

기평가를 반복 추론 과정에 활용한다.

본 연구의 방법적 구분점은 생성모델을 재학습하지 않고, 저장된 검색 궤적에서 계산한 현재 답변 대비 향후 최대 F1 이득을 별도의 경량 정책 모델에 학습시키는 것이다. 추론 시에는 정답이나 정답 홉 수 없이 현재까지 관찰한 상태만으로 STOP·SEARCH를 결정한다. 따라서 본 연구의 기여를 '최초의 단계별 학습 정책'으로 주장하지 않고, 중간 답변의 예상 품질 이득을 이용한 검색 계속 여부의 학습과 검증으로 한정한다.

Ⅲ. 본 론

1. 전체 시스템 구조

본 연구는 다중 홉 질의응답에서 모든 질문에 동일한 검색 횟수를 적용하는 대신, 현재까지 획득한 근거와 답변 상태에 따라 추가 검색 여부를 단계적으로 결정하는 검색 제어 정책을 제안한다.

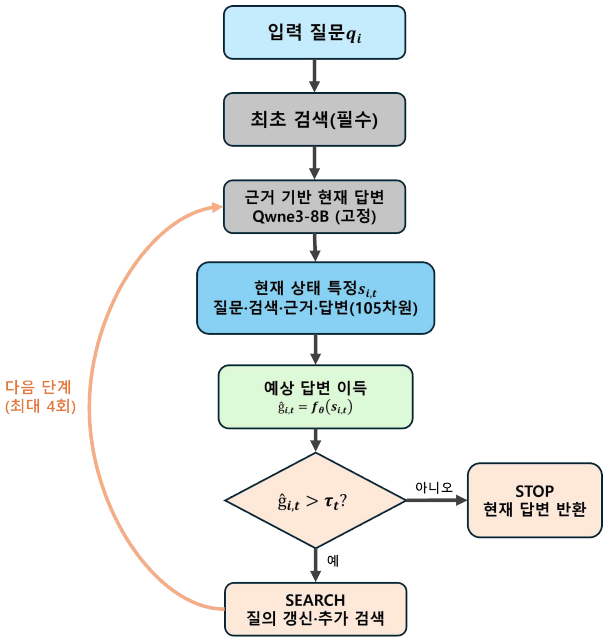


그림 1. 답변 이득 예측 기반 단계별 검색 제어의 전체 흐름.

그림 1은 최초 검색, 답변 생성, 상태 특징 추출 및 추가 검색 여부 판단으로 이어지는 제안 시스템의 동작 흐름을 나타낸다. 질문이 입력되면 하이브리드 검색을 통해 최초 근거 집합을 구성한다. 최초 검색은 모든 질문에서 필수로 수행된다. 이후 고정된 Qwen3-8B가 현재 근거를 이용하여 답변과 근거 연결 정보를 생성한다. 경량 정책 모델은 질문, 검색 점수, 근거 변화 및 현재 답변 특징으로 구성된 상태를 입력받아 추가 검색으로 얻을 수 있는 답변 이득을 예측한다.

예측된 답변 이득이 단계별 임곗값보다 작거나 같으면 정책은 STOP을 선택하고 현재 답변을 최종 답변으로 반환한다. 반대로 예상 답변 이득이 임곗값보다 크면 SEARCH를 선택한다. 이 경우 Qwen3-8B가 현재까지 부족한 정보를 반영하여 검색 질의를 갱신하고, 새로운 근거를 검색한 후 다시 답변을 생성한다. 이 과정은 정책이 STOP을 선택하거나 최대 4회 검색에 도달할 때까지 반복된다.

질의 갱신과 답변 생성에 사용하는 Qwen3-8B는 별도로 학습하지 않고 고정한다. 본 연구에서 학습하는 대상은 현재 상태에서 추가 검색의 답변 이득을 예측하는 히스토그램 기반 그레디언트 부스팅 회귀모델[15]이다. 정답은 정책 학습에 필요한 목표값을 구성하는 데만 사용하며, 실제 STOP·SEARCH 의사결정의 입력에는 포함하지 않는다.

2. 단계별 검색 궤적과 상태 표현

각 질문에 대해 최초 검색을 한 번 수행하고 이후 최대 세 번의 추가 검색이 가능한 궤적을 구성한다. 이에 따라 하나의 질문은 총 1회부터 최대 4회까지의 검색 결과와 단계별 생성 답변을 갖는다.

질문 q_i에 대해 t회의 검색으로 확보한 누적 근거 집합을 $E_{i,t}$, 해당 근거를 이용하여 생성한 현재 답변을 $\hat{a}_{i,t}$라고 정의한다. 정책은 최초 검색이 완료된 이후 세 개의 의사결정 지점에서 동작한다. 정책의 행동 공간은 다음과 같다.

$$\pi_\theta(s_{i,t}) \in \{\mathrm{STOP},\ \mathrm{SEARCH}\},\ t \in \{1,2,3\} \qquad (1)$$

여기서 $t=1$은 최초 검색을 수행한 상태이며, $t=2$와 $t=3$은 각각 추가 검색을 한 번과 두 번 수행한 상태를 의미한다. 세 번째 의사결정에서도 SEARCH가 선택되면 네 번째 검색을 수행하고 종료한다. 따라서 질문 i에 대해 정책이 선택하는 총 검색 횟수 d_i는 다음 범위를 갖는다.

$$d_i \in \{1,2,3,4\} \tag{2}$$

STOP은 현재 단계의 답변 $\hat{a}_{i,t}$를 최종 답변으로 반환하는 행동이다. SEARCH는 질의를 갱신하고 새로운 근거를 추가하는 행동이다.

정책 모델의 입력 상태 $s_{i,t}$는 의사결정 시점에서 실제로 관측할 수 있는 정보만을 이용하여 구성한다.

$$s_{i,t} = \phi\left(q_i,\ E_{i,1:t},\ R_{i,1:t},\ \hat{a}_{i,t},\ C_{i,t}\right) \tag{3}$$

여기서 $R_{i,1:t}$는 현재 단계까지의 검색 점수와 검색 결과 변화에 관한 통계이고, $C_{i,t}$는 현재 답변과 검색 근거 사이의 연결 구조를 의미한다. 상태 특징은 질의 특징, 검색 특징, 근거 집합 특징, 현재 답변 및 근거 연결 특징의 네 범주로 구성된다.

질의 특징은 질문 길이, 토큰 수, 숫자 포함 비율, 비교형 질문 여부, 의문사 유형 및 접속 표현 등을 포함한다. 이러한 특징은 질문의 언어적 구조와 잠재적인 복잡성을 나타낸다.

검색 특징은 현재 검색 단계, 후보 문서 수, 검색 점수의 최댓값·평균·최솟값, 상위 검색 결과 사이의 점수 차이, 새롭게 검색된 문서의 비율 및 이전 검색 문서의 유지 비율 등을 포함한다. 또한 질의 갱신 과정에서 보고된 근거 충분성, 부족한 정보의 길이 및 연속적으로 새로운 근거를 얻지 못한 횟수를 반영한다.

근거 집합 특징은 근거 문서 수, 고유 문서 제목 비율, 질문과 문서 제목의 단어 중첩, 검색 점수 분산, 새 근거 비율 및 기존 근거 유지 비율 등을 포함한다. 이를 통해 추가 검색으로 실제로 새로운 정보가 확보되었는지를 표현한다.

현재 답변 및 근거 연결 특징은 답변 길이, 알 수 없음 또는 불리언 답변 여부, 답변이 근거 문서와 제목에 포함되는 비율, 근거 연결의 절 수, 근거별 지지 정도 및 질문·답변·근거 사이의 중첩 등을 포함한다.

아직 수행하지 않은 검색 단계의 검색 및 근거 이력 특징은 0으로 채워, 모든 의사결정 단계에서 동일한 차원의 입력을 사용한다. 이 과정에서 미래 검색 결과의 실제 값은 사용하지 않는다. 최종 정책 모델에는 총 105개의 수치형 특징이 입력된다. 정답, 정답 근거를 식별하는 주석 정보, 정답 홉 수, 미래 단계의 F1 및 데이터셋 식별자는 정책 입력에서 제외한다.

3. 답변 이득 예측 정책 학습

정책 모델은 현재 검색을 종료했을 때의 답변과 이후 검색을 계속했을 때 얻을 수 있는 가장 좋은 답변 사이의 F1 차이를 예측한다. 질문 i의 검색 단계 t에서 사용하는 학습 목표값 $g_{i,t}$는 다음과 같이 정의한다.

$$g_{i,t} = \max_{k \in K_t} F1\left(\hat{a}_{i,k}, a_i^*\right) - F1\left(\hat{a}_{i,t}, a_i^*\right) \tag{4}$$

여기서 a_i^*는 질문 i의 정답이고, $\hat{a}_{i,t}$는 검색 단계 t에서 생성된 답변이다. $g_{i,t}$는 현재 답변과 이후 검색 단계에서 얻을 수 있는 최고 답변 사이의 성능 차이를 나타낸다.

목표값은 다음 한 번의 검색만 평가하지 않고, 이후 가능한 검색 단계 전체에서 얻을 수 있는 최대 답변 개선량을 반영한다. 따라서 다음 검색에서 즉시 성능이 향상되지 않더라도 이후 단계에서 유용한 근거를 얻을 수 있는 경우에는 양의 이득을 가질 수 있다. 반대로 이후의 모든 답변이 현재 답변보다 낮은 F1을 보이면 목표값은 음수가 될 수 있다.

정답과 단계별 실제 F1은 식 (4)의 학습 목표값을 만드는 과정에서만 사용한다. 실제 적용 단계에서는 정답을 알 수 없으므로 정책 모델은 현재 상태 $s_{i,t}$만을 이용하여 추가 검색의 답변 이득을 추정한다.

$$\hat{g}_{i,t} = f_\theta(s_{i,t}) \tag{5}$$

여기서 f_θ는 학습된 답변 이득 예측 모델이고, $\hat{g}_{i,t}$는 현재 상태에서 추가 검색을 수행할 때 예상되는 F1 이득이다.

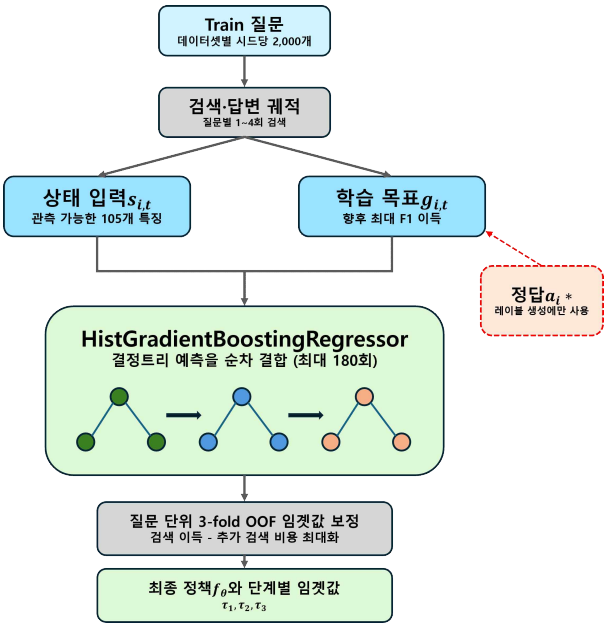


그림 2. 미래 답변 이득 예측 정책의 학습 과정.

그림 2는 저장된 검색 궤적에서 상태 특징과 학습 목표를 구성하여 답변 이득 예측 정책을 학습하는 과정을 나타낸다. 각 검색 단계에서 관측 가능한 105차원 특징을 입력으로, 후속 검색의 최대 F1 이득을 목표값으로 사용한다. 정답은 학습 목표를 구성하는 데만 사용하며, 실제 정책 입력에는 포함하지 않는다.

추가 검색 이득을 예측하는 모델로 HistGradientBoostingRegressor를 사용한다. 이 모델은 여러 결정트리를 순차적으로 학습하여 앞선 트리의 예측 오차를 보정하는 앙상블 회귀모델이다. 검색 점수, 근거 비율, 답변 길이 및 근거 변화와 같은 수치형 특징 사이의 비선형 관계를 학습할 수 있으며, 대규모 언어모델을 추가로 미세조정하는 방식보다 학습 및 추론 부담이 작다.

각 학습 표본 시드에서 HotpotQA, MuSiQue 및 2WikiMultiHopQA의 학습 분할로부터 데이터셋별 2,000문항씩 총 6,000문항을 추출한다. 각 질문에 대해 최대 4회까지의 검색 궤적을 생성하고, 1회·2회·3회 검색 후의 상태와 해당 시점에서 후속 검색으로 얻을 수 있는 최대 F1 이득을 각각 학습용 입력과 목표값으로 구성한다. 이에 따라 질문당 세 개씩, 총 18,000개의 상태 - 목표값 쌍으로 정책을 학습한다. 학습 표본 구성에 따른 변동을 확인하기 위해 추출 시드 42~46을 사용하여 총 5개의 정책을 독립적으로 학습한다.

표 1. 그래디언트 부스팅 회귀모델의 주요 설정

구분	설정값
학습 모델	HistGradientBoostingRegressor
손실 함수	Squared Error
학습률	0.05
최대 부스팅 반복 횟수	180회
최대 리프 노드수	15개
리프 노드당 최소 표본 수	25개
L2 규제 계수	3.0

표 1은 답변 이득 예측에 사용하는 그래디언트 부스팅 회귀 모델의 주요 설정을 나타낸다. 모든 학습 표본 시드에서 동일한 모델 설정을 사용하였다.

임곗값 보정을 위해 질문 단위의 3분할 교차검증을 수행한다. 동일한 질문에서 생성된 세 개의 상태는 같은 분할에 배치하여, 한 질문의 상태가 학습과 검증에 동시에 포함되지 않도록 한다. 각 분할에서 학습에 사용되지 않은 질문의 OOF 예측을 생성하고, 이를 이용하여 단계별 STOP·SEARCH 임곗값을 결정한다.

4. 단계별 검색 결정과 오프라인 평가

정책 모델이 검색 단계 t에서 예측한 답변 이득을 $\hat{g}_{i,t}$, 해당 단계의 적용하는 임곗값을 τ_t라고 하면 최종 행동은 다음과 같이 결정된다.

$$\pi_\theta(s_{i,t}) = \begin{cases} \text{SEARCH}, & \hat{g}_{i,t} > \tau_t \\ \text{STOP}, & \hat{g}_{i,t} \le \tau_t \end{cases} \quad (6)$$

모든 검색 단계에 하나의 임곗값을 공통으로 적용하지 않고 첫 번째, 두 번째 및 세 번째 의사결정 지점에 각각 τ_1, τ_2, τ_3을 적용한다. 검색 초기 단계와 최대 검색 횟수에 가까운 단계에서는 추가 검색의 기대 효과와 남아 있는 검색 기회가 다르기 때문이다.

단계별 임곗값 벡터를 $\boldsymbol{\tau} = (\tau_1, \tau_2, \tau_3)$라고 할 때, 임곗값은 학습 데이터의 OOF 예측에서 다음 목적함수를 최대화하도록 결정한다.

$$J(\boldsymbol{\tau}) = \frac{1}{N}\sum_{i=1}^{N}\left[\mathrm{F1}_{\mathrm{i},\mathrm{d}_\mathrm{i}(\boldsymbol{\tau})} - \lambda(\mathrm{d}_\mathrm{i}(\boldsymbol{\tau}) - 1)\right] \quad (7)$$

여기서 $d_i(\boldsymbol{\tau})$는 임곗값 벡터 $\boldsymbol{\tau}$를 적용했을 때 질문 i에서 수행된 총 검색 횟수이고, $F1_{i,d_i(\boldsymbol{\tau})}$는 정책이 종료한 단계의 답변 F1이다. 최초 검색은 필수이므로 $d_i(\boldsymbol{\tau}) - 1$은 추가 검색 횟수를 의미한다.

추가 검색 비용 λ는 0부터 1 사이로 정규화된 F1을 기준으로 0.001로 설정한다. 이는 100점 기준 F1에서 추가 검색 1회당 0.1점의 비용에 해당한다. 동일한 목적함숫값을 갖는 임곗값 조합이 존재하면 평균 검색 횟수가 적은 조합을 선택한다. 추가 검색 비용은 단계별 임곗값을 보정하는 목적함수에 반영된다. 실제 의사결정에서는 예측된 답변 이득과 보정된 임곗값만 비교하며, 비용을 별도로 다시 가산하지 않는다.

평가는 각 질문에 대해 미리 생성한 1회부터 4회까지의 검색·답변 궤적을 이용하여 수행한다. 최초 검색 상태에서 정책을 적용하고 SEARCH가 선택되면 저장된 다음 검색 단계로 이동한다. STOP이 선택되면 해당 단계에서 생성된 답변을 최종 답변으로 선택한다. 세 번째 의사결정 지점에서도 SEARCH가 선택되면 네 번째 검색 단계의 답변을 반환하고 종료한다.

오프라인 궤적 재생 방식은 모든 정책을 동일한 검색 및 답변 기록 위에서 비교할 수 있으므로 정책 선택의 차이를 반복 가능한 조건에서 평가할 수 있다는 장점이 있다. 또한 평가 과정에서도 정답이나 아직 수행되지 않은 미래 단계의 F1은 정책 입력으로 사용하지 않는다. 정답은 정책이 선택한 최종 답변의 EM과 F1을 계산하는 데만 사용한다.

Ⅳ. 실험 및 결과

1. 실험 설정

본 실험은 제안한 답변 이득 예측 정책이 질문과 현재 검색 상태에 따라 검색 횟수를 조절할 수 있는지를 검증하는 것을 목적으로 한다. 평가에는 다중 홉 질의응답 데이터셋인 HotpotQA[6], MuSiQue[7] 및 2WikiMultiHopQA[8]를 사용하였다. 각 데이터셋에서 제공하는 질문별 distractor 문서 집합을 검색 대상으로 사용하였으며, 전체 문서 집합을 대상으로 하는 개방형 검색 환경은 적용하지 않았다.

표 2. 데이터셋 구성

데이터셋	시드별 학습 문항	평가 문항 수	최대 검색 횟수
HotpotQA	2,000	7,405	4회
MuSiQue	2,000	2,417	4회
2WikiMultiHopQA	2,000	12,576	4회

표 2는 데이터셋별 정책 학습 및 평가 구성을 나타낸다. 각 학습 표본 시드에서 데이터셋별 2,000문항을 추출하며, 학습된 정책은 각 데이터셋의 전체 검증 분할에서 평가한다. 모든 시드는 동일한 평가 문항을 사용하고, 총 검색 횟수의 상한은 4회로 설정한다.

검색 문서는 문자 기준 900자 단위로 분할하였으며, 인접 청크 사이에는 140자의 중첩을 적용하였다. 검색에는 BM25[16]와 intfloat/multilingual-e5-base[17] 기반 밀집 검색을 결합한 하이브리드 검색을 사용하고, BAAI/bge-reranker-v2-m3[18]로 검색 결과를 재정렬하였다. 최초 검색에서는 15개의 후보를 생성한 후 상위 5개 근거를 사용하였다. 후속 검색에서는 8개의 후보 중 기존 근거와 중복되지 않는 상위 근거 한 개를 추가하였다. 답변 생성에 입력되는 근거는 최대 8개, 전체 문맥 길이는 6,000자로 제한하였다.

질의 갱신과 답변 생성에는 Qwen3-8B를 사용하였다. 샘플링 온도(temperature)는 0으로 설정하고 내부 thinking 기능은 사용하지 않았다. 질의 갱신의 최대 출력 길이는 80토큰, 답변 생성의 최대 출력 길이는 256토큰으로 설정하였다.

비교 방법으로 모든 질문에 동일한 검색 횟수를 적용하는 고정 1회, 2회, 3회 및 4회 검색 방식을 사용하였다. 고정 k회 검색은 저장된 검색 궤적에서 k번째 단계까지 획득한 근거를 이용해 생성한 답변을 평가한다. 또한 질문 상태를 이용한 검색 배분의 효과를 확인하기 위해 제안 정책과 동일한 검색 깊이 분포를 유지하면서 질문과 무관하게 종료 깊이를 배분하는

검색 깊이 분포 일치 무작위 종료 방식을 비교하였다.

평가 지표로는 EM(Exact Match), 토큰 단위 F1(token-level F1-score), 평균 검색 횟수, 고정 4회 대비 검색 감소율, 답변 생성 토큰 및 추정 지연시간을 사용하였다. EM과 F1은 100점 기준으로 보고하였다. 제안 정책의 결과는 5개 학습 표본 시드의 평균과 표본 표준편차로 제시하였다.

비교군 대비 F1 차이의 불확실성을 평가하기 위해 각 학습 표본 시드에서 문항 단위 대응 부트스트랩을 적용하였다. 동일 문항에 대한 제안 정책과 비교군의 F1 차이를 복원 추출하고, 평균 차이 분포의 2.5 및 97.5 백분위수를 95% 신뢰구간으로 산출하였다. 이 신뢰구간은 평가 문항에 따른 성능 차이의 불확실성을 나타내며, 학습 표본 구성에 따른 변동을 나타내는 시드 간 표준편차와 구분된다. 고정 검색 비교군은 정책 학습을 수행하지 않으므로 저장된 동일 궤적에서 계산한 단일 값으로 제시하였다.

2. 답변 성능 및 검색 횟수

표 3. 검색 방식에 따른 F1 성능

검색 방식	HotpotQA	MuSiQue	2Wiki
고정 1회	70.32	39.30	59.26
고정 2회	71.36	41.96	62.95
고정 3회	71.69	44.09	63.93
고정 4회	71.78	44.49	64.01
제안 정책	72.05±0.14	44.97±0.48	64.81±0.48

표 3은 고정 검색 방식과 제안 정책의 F1 성능을 나타낸다. 제안 정책의 결과는 5개 학습 표본 시드의 평균과 표본 표준편차로 제시하였다.

고정 검색 방식에서는 세 데이터셋 모두 검색 횟수가 증가함에 따라 평균 F1이 높아졌지만, 추가 검색으로 얻는 성능 향상 폭은 점차 감소하였다. HotpotQA는 고정 1회에서 2회로 증가할 때 1.04점 향상되었지만, 고정 3회에서 4회로 증가할 때는 0.09점 향상되는 데 그쳤다. 2WikiMultiHopQA에서도 고정 3회와 4회의 차이는 0.08점이었다. 이는 검색 횟수를 일괄적으로 늘리는 방식의 평균적인 추가 이득이 제한적일 수 있음을 보여준다.

제안 정책의 평균 F1은 HotpotQA 72.05점, MuSiQue 44.97점, 2WikiMultiHopQA 64.81점이었다. 고정 4회 검색과 비교하면 각각 0.27점, 0.49점 및 0.79점 높았다. 성능 차이는 반올림 전의 값을 기준으로 계산하였다.

표 4. 검색 방식에 따른 EM 성능

검색 방식	HotpotQA	MuSiQue	2Wiki
고정 1회	56.60	30.29	52.66
고정 2회	57.53	32.77	56.23
고정 3회	57.64	34.67	57.11
고정 4회	57.73	34.92	57.16
제안 정책	58.01±0.13	35.18±0.51	58.01±0.46

표 4는 각 검색 방식의 EM 성능을 나타낸다. 제안 정책은 고정 4회 검색보다 HotpotQA에서 0.28점, MuSiQue에서 0.26점, 2WikiMultiHopQA에서 0.84점 높은 평균 EM을 기록하였다.

표 5. 제안 정책의 평균 검색 횟수 및 감소율

데이터셋	평균 검색 횟수	검색 감소율
HotpotQA	2.90±0.51	27.40±12.76%
MuSiQue	3.17±0.34	20.79±8.59%
2Wiki	2.84±0.36	28.99±9.05%

표 5는 제안 정책의 평균 검색 횟수와 고정 4회 대비 검색 감소율을 나타낸다. 검색 감소율은 고정 4회 검색을 기준으로 $(4 - \text{평균 검색 횟수})/4 \times 100$으로 계산하였다. 제안 정책의 평균 검색 횟수는 HotpotQA 2.90회, MuSiQue 3.17회, 2WikiMultiHopQA 2.84회로, 고정 4회보다 각각 27.40%, 20.79% 및 28.99% 감소하였다. 특히 HotpotQA와 2WikiMultiHopQA에서는 평균 3회 미만의 검색으로 고정 4회보다 높은 평균 F1을 기록하였다. MuSiQue에서는 상대적으로 많은 검색을 수행하였으며, 학습 표본에 따른 검색 횟수의 변동도 나타났다.

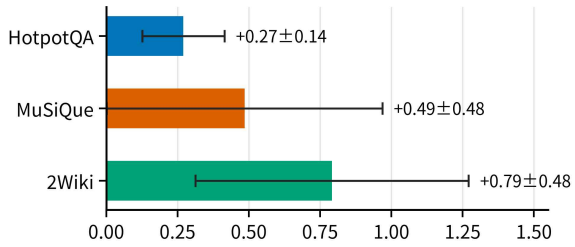


그림 3. 고정 4회 검색 대비 F1 변화.

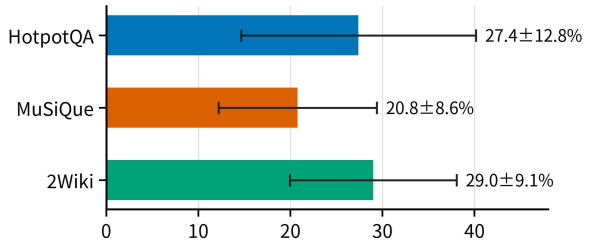


그림 4. 고정 4회 검색 대비 검색 감소율.

그림 3과 그림 4는 고정 4회 검색 대비 제안 정책의 F1 변화와 검색 감소율을 각각 나타낸다. 막대는 5개 학습 표본 시드의 평균이며, 오차막대는 시드 간 표본 표준편차를 나타낸다. 세 데이터셋 모두 시드 평균에서 F1이 높아지면서 검색 횟수가 감소하였다. 다만 답변 성능의 변화와 검색 감소 폭은 학습 표본에 따라 달라졌다. 고정 4회 대비 F1 차이의 불확실성은 표 6의 시드별 신뢰구간으로 추가 분석하였다.

표 6. 학습 표본 시드별 4회 검색 대비 F1 차이와 95% 신뢰구간

데이터셋	시드	F1 차이	95% 신뢰구간
HotpotQA	42	+0.148	[−0.165, +0.449]
	43	+0.397	[−0.005, +0.800]
	44	+0.085	[−0.372, +0.552]
	45	+0.387	[+0.016, +0.767]
	46	+0.335	[+0.022, +0.667]
MuSiQue	42	+0.748	[+0.108, +1.368]
	43	+0.717	[−0.224, +1.680]
	44	−0.377	[−1.427, +0.633]
	45	+0.663	[−0.113, +1.428]
	46	+0.675	[−0.172, +1.513]
2Wiki	42	+0.977	[+0.586, +1.397]
	43	+1.127	[+0.685, +1.578]
	44	+0.045	[−0.403, +0.501]
	45	+1.213	[+0.822, +1.613]
	46	+0.598	[+0.253, +0.952]

표 6은 학습 표본 시드별 고정 4회 검색 대비 F1 차이와 문항 단위 대응 부트스트랩 95% 신뢰구간을 나타낸다. HotpotQA와 2WikiMultiHopQA에서는 5개 시드 모두 고정 4회보다 높은 F1을 기록하였다. MuSiQue에서는 5개 중 4개 시드에서 높은 F1을 보였으나, 시드 44에서는 0.38점 낮았다.

신뢰구간의 하한이 0보다 높은 경우는 HotpotQA에서 시드 45·46, MuSiQue에서 시드 42, 2WikiMultiHopQA에서 시드 42·43·45·46이었다. 나머지 8개 비교에서는 신뢰구간이 0을 포함하였다. 따라서 제안 정책은 5개 학습 표본 시드 평균에서 검색 횟수가 감소하면서 F1이 높아졌으나, 모든 시드에서 통계적으로 유의한 성능 우위가 확인된 것은 아니다.

3. 질문별 검색 배분 효과

제안 정책의 결과가 단순히 특정 검색 횟수 분포를 사용했기 때문에 나타난 것인지 확인하기 위해 검색 깊이 분포 일치 무작위 종료 방식과 비교하였다. 이 비교군은 각 시드에서 제안 정책이 선택한 1회부터 4회까지의 검색 깊이 비율을 동일하게 유지하지만, 어떤 질문에 추가 검색을 배분할지는 질문 내용 및 현재 상태와 무관하게 결정한다.

무작위 시행에 따른 우연한 변동을 제거하기 위해 실제 무작위 배정을 한 번 수행하는 대신, 각 검색 깊이의 F1과 제안 정책의 검색 깊이 비율을 이용해 무작위 배정의 기대 F1을 계산하였다. 따라서 제안 정책과 비교군은 동일한 검색 깊이 분포를 사용하며, 질문 상태에 따라 추가 검색 대상을 선택했는지만 다르다.

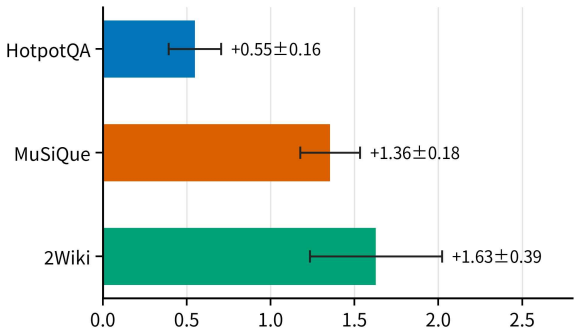


그림 5. 검색 깊이 분포 일치 무작위 종료 대비 제안 정책의 F1 향상.

그림 5는 제안 정책과 검색 깊이 분포 일치 무작위 종

료 기준선 간의 F1 차이를 나타낸다. 막대는 5개 학습 표본 시드의 평균 차이이며, 오차막대는 시드 간 표본 표준편차이다. 제안 정책은 HotpotQA에서 0.55±0.16점, MuSiQue에서 1.36±0.18점, 2WikiMultiHopQA에서 1.63±0.39점 높은 F1을 기록하였다.

표 7. 학습 표본 시드별 검색 깊이 분포 일치 무작위 종료 대비 F1 차이와 95% 신뢰구간

데이터셋	시드	F1 차이	95% 신뢰구간
HotpotQA	42	+0.347	[+0.082, +0.605]
	43	+0.564	[+0.299, +0.829]
	44	+0.782	[+0.468, +1.088]
	45	+0.553	[+0.266, +0.842]
	46	+0.496	[+0.236, +0.789]
MuSiQue	42	+1.106	[+0.546, +1.669]
	43	+1.530	[+0.877, +2.162]
	44	+1.442	[+0.740, +2.159]
	45	+1.232	[+0.632, +1.862]
	46	+1.465	[+0.797, +2.108]
2Wiki	42	+1.828	[+1.511, +2.167]
	43	+1.636	[+1.339, +1.954]
	44	+2.059	[+1.699, +2.433]
	45	+1.617	[+1.319, +1.933]
	46	+0.999	[+0.713, +1.307]

표 7은 검색 깊이 분포 일치 무작위 종료 기준선 대비 시드별 F1 차이와 95% 신뢰구간을 나타낸다. 세 데이터셋과 5개 학습 표본 시드로 구성된 총 15개 비교에서 모두 제안 정책의 F1이 높았으며, 각 신뢰구간의 하한도 0보다 높았다.

두 방식은 동일한 검색 깊이 분포를 사용하므로 평균 검색 횟수가 같다. 이 조건에서 제안 정책이 높은 F1을 기록한 것은 검색 횟수 분포뿐 아니라, 현재 상태를 바탕으로 어떤 질문에 추가 검색을 배분하는지가 답변 성능에 기여함을 보여준다. 이는 학습된 정책의 질문별 검색 배분 효과를 뒷받침한다.

4. 생성 비용의 트레이드오프 및 한계

검색 횟수 감소에 따른 생성 비용의 변화를 확인하기 위해 답변 생성 모델의 누적 출력 토큰과 추정 지연시간을 분석하였다. 제안 정책은 각 검색 단계에서 현재 답변 상태를 관측해야 하므로, 검색 횟수 감소와 함께 발생하는 중간 답변 생성 비용을 별도로 평가하였다.

표 8. 고정 4회 검색과 제안 정책의 답변 생성 토큰 비교

데이터셋	고정 4회	제안 정책	증가율
HotpotQA	51.02	141.57±26.52	177.49%
MuSiQue	50.08	157.23±17.75	213.98%
2Wiki	60.92	169.92±20.56	178.91%

표 8은 고정 4회 검색과 제안 정책의 질의당 평균 답변 생성 출력 토큰을 나타낸다. 제안 정책의 값은 종료 시점까지 생성한 중간 답변과 최종 답변의 출력 토큰을 누적한 것이다. 이 집계에는 입력 토큰과 질의 갱신 토큰은 포함하지 않는다.

제안 정책의 누적 출력 토큰은 고정 4회보다 HotpotQA에서 177.49%, MuSiQue에서 213.98%, 2WikiMultiHopQA에서 178.91% 증가하였다. 고정 4회 방식은 검색을 마친 뒤 최종 답변을 한 번 생성하지만, 제안 정책은 단계별 의사결정을 위해 중간 답변을 생성하므로 출력 토큰이 증가하였다.

표 9. 고정 4회 검색과 제안 정책의 추정 지연시간 비교

데이터셋	고정 4회	제안 정책	증가율
HotpotQA	2.76초	3.46±0.69초	25.29%
MuSiQue	3.10초	4.14±0.49초	33.36%
2Wiki	2.40초	3.16±0.43초	31.41%

표 9는 저장된 실행 기록을 이용하여 계산한 질의당 평균 추정 지연시간을 나타낸다. 제안 정책은 고정 4회보다 HotpotQA에서 25.29%, MuSiQue에서 33.36%, 2WikiMultiHopQA에서 31.41% 증가하였다. 이는 검색 횟수 감소에도 불구하고 중간 답변 생성 시간이 추가되었기 때문이다.

추정 지연시간은 최초 검색 시간, 선택된 깊이까지의 질의 갱신·검색 시간 추정치 및 필요한 답변 생성 시간을 합산하여 계산하였다. 질의 갱신은 저장된 누적 시간을 사용하고, 후속 검색 및 부대 처리 시간은 전체 기록에서 검색 단계 수에 비례하여 배분하였다. 따라서 이 값은 온라인 서비스에서 측

정한 종단 간 지연시간과 구분된다.

제안 정책은 고정 4회보다 평균 검색 횟수를 줄이면서 5개 학습 표본 시드 평균 F1과 EM을 높였으나, 단계별 답변 상태를 관측하는 과정에서 출력 토큰과 추정 지연시간은 증가하였다. 이는 검색 횟수 감소와 생성 비용 증가 사이의 트레이드오프를 보여준다. 따라서 제안 방법의 효과는 답변 성능과 검색 횟수의 관계로 평가하고, 상태 관측에 필요한 생성 비용을 함께 고려해야 한다.

본 실험은 미리 생성한 검색 궤적을 이용한 오프라인 평가이며, 검증 분할은 앞선 방법 개발 과정에서도 사용되었다. 또한 검색 대상이 질문별 방해 문서 집합으로 제한되어 있어 실제 개방형 검색 환경과 차이가 있다. 향후 방법 선택에 사용되지 않은 독립 평가 집합과 온라인 환경에서 결과를 재검증하고, 중간 답변 생성에 따른 상태 관측 비용을 줄이는 방법을 검토할 필요가 있다.

V. 결 론

본 연구는 다중 홉 질의응답에서 현재 근거와 답변 상태로부터 후속 검색의 답변 이득을 예측하고, 학습된 그래디언트 부스팅 정책으로 검색 지속 여부를 단계적으로 결정하는 방법을 제안하였다. 질의 갱신과 답변 생성에 사용하는 Qwen3-8B는 고정하고 경량 정책만 학습하였으며, 최초 검색 이후 최대 4회의 상한 안에서 질문별 검색 횟수를 조절하였다.

세 데이터셋의 전체 검증 분할을 이용한 오프라인 궤적 재생 평가에서, 제안 정책은 고정 4회보다 5개 시드 평균 F1이 HotpotQA에서 0.27점, MuSiQue에서 0.49점, 2WikiMultiHopQA에서 0.79점 높았다. 평균 검색 횟수는 각각 27.40%, 20.79%, 28.99% 감소하였다. 다만 고정 4회 대비 신뢰구간은 일부 시드에서 0을 포함하여, 모든 시드에서 유의한 성능 우위가 확인된 것은 아니다.

동일한 검색 깊이 분포의 무작위 종료 기준선과 비교하면 F1은 각각 0.55점, 1.36점, 1.63점 높았으며, 15개 데이터셋·시드 비교 모두 신뢰구간의 하한이 0보다 높았다. 이는 학습된 정책이 질문 상태에 따라 추가 검색을 배분하는 데 유효한 정보를 활용할 수 있음을 뒷받침한다.

한편 단계별 중간 답변 생성으로 출력 토큰과 추정 지연시간이 증가하여, 검색 횟수 감소와 생성 비용 사이의 트레이드오프가 나타났다. 향후 독립 평가 집합과 온라인 검색 환경에서 결과를 재검증하고, 답변 상태 관측에 필요한 생성 비용을 줄이는 방법을 연구할 예정이다.

REFERENCES

[1] P. Lewis, E. Perez, A. Piktus, et al., “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks,” Advances in Neural Information Processing Systems, vol. 33, pp. 9459-9474, 2020.

[2] H. Trivedi, N. Balasubramanian, T. Khot, and A. Sabharwal, “Interleaving Retrieval with Chain-of-Thought Reasoning for Knowledge-Intensive Multi-Step Questions,” Proc. of the 61st Annual Meeting of the Association for Computational Linguistics, vol. 1, pp. 10014-10037, 2023.

[3] S. Jeong, J. Baek, S. Cho, S.J. Hwang, and J. Park, “Adaptive-RAG: Learning to Adapt Retrieval-Augmented Large Language Models through Question Complexity,” Proc. of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, vol. 1, pp. 7036-7050, 2024.

[4] Y. Zhu, L. Pang, Y. Lan, H. Shen, and X. Cheng, “Adaptive Information Seeking for Open-Domain Question Answering,” Proc. of the 2021 Conference on Empirical Methods in Natural Language Processing, pp. 3615-3626, 2021.

[5] A. Yang et al., “Qwen3 Technical Report,” arXiv preprint arXiv:2505.09388, 2025.

[6] Z. Yang, P. Qi, S. Zhang, et al., “HotpotQA: A Dataset for Diverse, Explainable Multi-hop Question Answering,” Proc. of the 2018 Conference on Empirical Methods in Natural Language Processing, pp. 2369-2380, 2018.

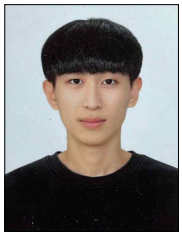
[7] H. Trivedi, N. Balasubramanian, T. Khot, and A. Sabharwal, “MuSiQue: Multihop Questions via Single-hop Question Composition,” Transactions of the Association for Computational Linguistics, vol. 10, pp. 539-554, 2022.

[8] X. Ho, A.K.D. Nguyen, S. Sugawara, and A. Aizawa, “Constructing A Multi-hop QA Dataset for Comprehensive Evaluation of Reasoning Steps,” Proc. of the 28th International Conference on Computational Linguistics, pp. 6609-6625, 2020.

[9] R. Zhu, X. Liu, Z. Sun, Y. Wang, and W. Hu,

"Mitigating Lost-in-Retrieval Problems in Retrieval Augmented Multi-Hop Question Answering," Proc. of the 63rd Annual Meeting of the Association for Computational Linguistics, vol. 1, pp. 22362-22375, 2025.
[10] X. Tang, Q. Gao, J. Li, N. Du, Q. Li, and S. Xie, "MBA-RAG: a Bandit Approach for Adaptive Retrieval-Augmented Generation through Question Complexity," Proc. of the 31st International Conference on Computational Linguistics, pp. 3248-3254, 2025.
[11] Z. Jiang, F. Xu, L. Gao, et al., "Active Retrieval Augmented Generation," Proc. of the 2023 Conference on Empirical Methods in Natural Language Processing, pp. 7969-7992, 2023.
[12] W. Su, Y. Tang, Q. Ai, Z. Wu, and Y. Liu, "DRAGIN: Dynamic Retrieval Augmented Generation Based on the Real-Time Information Needs of Large Language Models," Proc. of the 62nd Annual Meeting of the Association for Computational Linguistics, vol. 1, pp. 12991-13013, 2024.
[13] A. Asai, Z. Wu, Y. Wang, A. Sil, and H. Hajishirzi, "Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection," Proc. of the 12th International Conference on Learning Representations, 2024.
[14] Z. Chu, H. Fan, J. Chen, et al., "Self-Critique Guided Iterative Reasoning for Multi-hop Question Answering," Findings of the Association for Computational Linguistics: ACL 2025, pp. 2415-2438, 2025.
[15] J.H. Friedman, "Greedy Function Approximation: A Gradient Boosting Machine," The Annals of Statistics, vol. 29, no. 5, pp. 1189-1232, 2001.
[16] S.E. Robertson and H. Zaragoza, "The Probabilistic Relevance Framework: BM25 and Beyond," Foundations and Trends in Information Retrieval, vol. 3, no. 4, pp. 333-389, 2009.
[17] L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder, and F. Wei, "Multilingual E5 Text Embeddings: A Technical Report," arXiv preprint arXiv:2402.05672, 2024.
[18] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian, and Z. Liu, "M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation," Findings of the Association for Computational Linguistics: ACL 2024, pp. 2318-2335, 2024.

저 자 소 개



이정호(정회원)

2026년 국립순천대학교 멀티미디어공학과 졸업(공학사).
2026년~현재 국립순천대학교 스마트융합학부 멀티미디어공학전공 석사과정.

<주관심분야 : 대형언어모델, 자연어처리>



정세훈(정회원)

2012년 국립순천대학교 멀티미디어공학과 졸업(공학석사).
2017년 국립순천대학교 멀티미디어공학과 졸업(공학박사).
2018년 영산대학교 빅데이터융합전공 조교수.
2020년 안동대학교 창의융합학부 조교수.
2022년~현재 국립순천대학교 컴퓨터공학과 조교수.

<주관심분야 : 소프트웨어공학, 강화학습, 블록체인, 딥러닝, 데이터 마이닝, 빅데이터 분석 및 예측>



심춘보(정회원)

1996년 전북대학교 컴퓨터공학과 졸업(공학사).
1998년 전북대학교 컴퓨터공학과 졸업(공학석사).
2003년 전북대학교 컴퓨터공학과 졸업(공학박사).
2005년~현재 국립순천대학교 인공지능공학부 교수.

<주관심분야 : 빅데이터, 블록체인, 딥러닝, 생성모델, 자연어처리, 강화학습>